Comparação de LLMs: gemma4:12b × qwen3:14b

Nov 12, 2026 · @Pedro

Recomendação: usar o gemma4:12b no Mac M4 de 24 GB. Os dois modelos empatam em todas as métricas de segurança: nenhum inventou, citou errado ou deixou de se abster. O gemma responde de forma mais completa (cobertura de 0,61 contra 0,58), acerta 22 de 22 rotas (qwen 21 de 22) e gera em 78 s (qwen 87 s). O qwen só é mais rápido no classificador da barra do mapa (4,2 s contra 7,5 s).

Como o teste foi feito

Os dois modelos responderam às mesmas perguntas, sobre o mesmo índice de documentos, no mesmo computador. Só o modelo de linguagem mudou.

Item	Configuração
Computador	Mac M4, 24 GB de memória unificada (cerca de 16 GB disponíveis para a GPU)
Modelos	gemma4:12b (8,0 GB) e qwen3:14b (9,3 GB), os dois inteiros na GPU, um carregado por vez
Execução	Ollama local, temperatura 0,1, resposta em JSON com esquema, raciocínio desligado (`think: false`)
Índice	24 fontes, 533 trechos, 1.472 vetores, já com as correções da auditoria de extração
Busca	Embeddings MiniLM multilíngue + ChromaDB, 5 trechos por pergunta, reordenação híbrida
Teste 1	Avaliação completa do RAG: 18 perguntas (13 com resposta na base, 5 sem resposta ou adversárias)
Teste 2	Classificador da barra do mapa: 22 perguntas com rota conhecida
Tentativas	Uma execução completa por modelo

Como a busca é a mesma, os dois recebem os mesmos trechos. As diferenças medidas vêm só da forma como cada modelo lê esses trechos e redige a resposta.

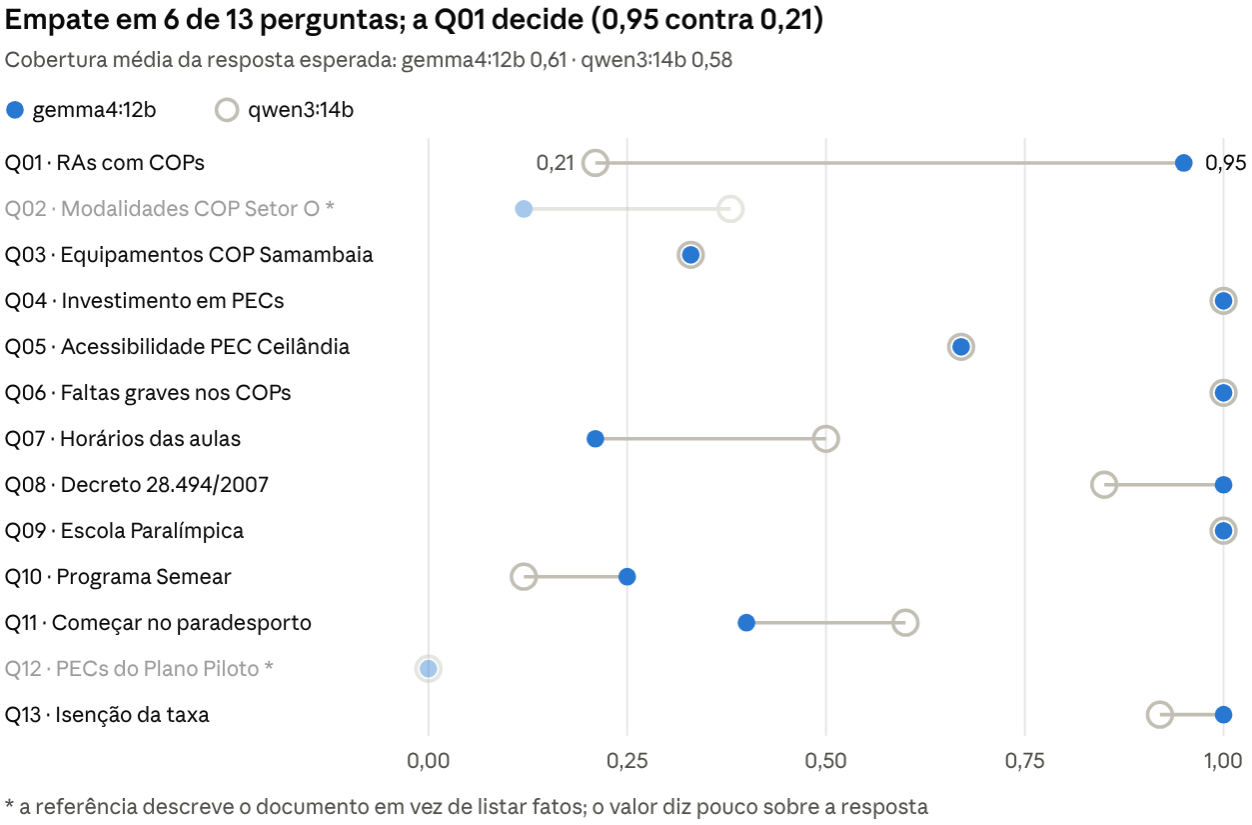
Avaliação do RAG (18 perguntas)

Os dois passaram na verificação automática de qualidade com nota máxima em segurança. A diferença está na completude e no tempo.

Métrica	gemma4:12b	qwen3:14b	Melhor
Verificação automática (portão)	OK	OK	empate
Recall médio@5	1,00	1,00	empate (mesma busca)
Acerto de ao menos uma fonte	1,00	1,00	empate
Cobertura de citações	1,00	1,00	empate
Suporte factual médio	1,00	1,00	empate
Afirmações sem suporte	0	0	empate
Citações inválidas	0	0	empate
Abstenções corretas (Q14–Q18)	5 de 5	5 de 5	empate
Falsas abstenções	0	0	empate
Gerações incompletas	0	0	empate
Tentativas médias por resposta	1,00	1,00	empate
Cobertura da resposta esperada	**0,61**	0,58	gemma
Frases por resposta (média)	3,2	3,8	—
Tempo médio de geração	**78 s**	87 s	gemma

Cobertura da resposta esperada é a fração dos termos da referência de cada pergunta que aparecem na resposta, sem acentos e no singular. Ela mede completude, não correção: uma resposta pode citar os termos certos e ainda estar errada, ou o contrário. Por isso as respostas que divergiram foram lidas uma a uma (seção abaixo).

Cobertura da resposta esperada, pergunta a pergunta



Avaliações de 12/11/2026 (gemma às 11h51, qwen às 15h33) · 13 perguntas com resposta na base · cobertura = termos da referência presentes na resposta

O gemma cobre mais em 4 perguntas e o qwen em 3; nas outras 6 empatam. A média fica próxima porque o qwen ganha na Q07 e na Q11, mas a Q01 é um erro de conteúdo, não só de palavras: a resposta do qwen omite 10 das 11 regiões.

Classificador da barra do mapa (22 perguntas)

O gemma acertou todas as rotas; o qwen errou uma, mas classificou quase duas vezes mais rápido. As perguntas foram escolhidas para não cair no atalho "tipo + região", que responde sem modelo.

Rota esperada	Perguntas	gemma4:12b	qwen3:14b
mapa (localizar espaços)	6	6	6
documentos (horário, funcionamento, acessibilidade)	4	4	4
duvidas (matrícula, regras, programas, leis)	5	5	5
fora_escopo	4	4	4

Rota esperada	Perguntas	gemma4:12b	qwen3:14b
esclarecer	3	3	2
Total de acertos	**22**	**22**	**21**
Erros de formato (JSON inválido)	—	0	0
Tempo médio por pergunta	—	7,5 s	**4,2 s**

O erro do qwen foi "tem vaga?": ele mandou para a aba Dúvidas em vez de pedir mais informação. Não é grave (a pesquisa de dúvidas se absteria ou responderia sobre vagas do edital), mas a pergunta não diz de qual local.

Exemplos usados: "tem algum lugar pra nadar em Ceilândia?" (mapa), "qual o horário dos Centros Olímpicos?" (documentos), "quem é isento da taxa da Escola de Esportes?" (dúvidas), "onde comprar cerveja no Guará?" (fora do escopo), "Onde posso jogar?" (esclarecer).

Leitura das respostas que divergiram

O erro decisivo está na Q01: o qwen cita só Ceilândia como região com Centro Olímpico, quando são 11. Essa leitura foi feita por IA e precisa ser confirmada na revisão humana.

Pergunta	Esperado	gemma4:12b	qwen3:14b	Melhor
Q01 · RAs com Centros Olímpicos	12 COPs em 11 RAs	Lista as 11 RAs	Cita só Ceilândia (incompleta)	gemma
Q02 · modalidades do COP Setor O	Lista da p. 22 do DOC-004	Lista completa, em 4 frases	Parcial, com um termo estranho ("PFC Ginástica Rítmica")	gemma
Q07 · horários das aulas	6h45 às 21h; fins de semana como convivência	Horários por dia, sem contradição	Inclui os fins de semana, mas diz "segunda a sexta 6h45" e depois "segunda 14h"	gemma
Q10 · Programa Semear	Dois eixos: formação (a partir de 6 anos) e paradesporto	Genérica, sem os eixos	Genérica, sem os eixos	empate

Pergunta	Esperado	gemma4:12b	qwen3:14b	Melhor
Q11 · começar no paradesporto	Secretarias, clubes do CPB, FAQ	Completa	Completa	empate

O qwen também repete o sujeito em toda frase ("O Programa SEMEAR…", "O COP do Setor O…"), o que deixa a leitura mais pesada. Nas demais perguntas, as respostas dos dois são equivalentes.

Limites e o que falta decidir

O teste basta para escolher o modelo deste Mac. Para a entrega final faltam duas decisões do grupo.

- **Amostra pequena:** uma execução por modelo, 18 perguntas de avaliação e 22 de rota. A diferença de cobertura (0,61 contra 0,58) é pequena; o que pesa é o erro de conteúdo da Q01.
- **Vale para ± 16 GB de GPU:** no computador pessoal o padrão do projeto é o gemma4:26b, que não entrou nesta comparação e nunca completou uma avaliação inteira.
- **Execuções em horários diferentes:** gemma às 11h51, qwen às 15h33. O código do RAG e o índice são os mesmos.
- **Qualidade final é humana:** as métricas automáticas mostram que os dois são seguros; qual responde melhor depende da revisão das respostas.

- [ ] Definir em qual computador será a apresentação (Mac com gemma4:12b ou computador pessoal com gemma4:26b)
- [ ] Se for o computador pessoal: rodar a avaliação completa com o gemma4:26b e conferir o tempo por resposta
- [ ] Revisar as respostas do modelo escolhido na planilha `evidencias/revisao_humana_rag.md`
- [ ] Registrar a escolha do modelo no README e no relatório da fase 4

Como repetir

Qualquer pessoa do grupo pode refazer o teste com o Ollama instalado e o índice montado (`python -m pontoativo_rag.ingestao`).

1. Baixar o modelo: `ollama pull qwen3:14b`
2. Avaliação completa com cada modelo (cerca de 20 minutos cada):

    - `PONTOATIVO_OLLAMA_MODEL=qwen3:14b python -m pontoativo_rag.avaliacao --verificar-qualidade --rotulo qwen3_14b`
    - `PONTOATIVO_OLLAMA_MODEL=gemma4:12b python -m pontoativo_rag.avaliacao --verificar-qualidade --rotulo gemma4_12b`
3. No Windows (PowerShell), definir o modelo antes: `$env:PONTOATIVO_OLLAMA_MODEL = 'qwen3:14b'`
4. Comparar as duas execuções: `python -m pontoativo_rag.avaliacao --comparar-anterior <gemma>.jsonl --comparar-atual <qwen>.jsonl`

Arquivos de evidência desta comparação (branch local de teste, ainda sem commit):

- `evidencias/historico/avaliacao_20261112_115119_gemma4_12b_correcao_auditoria.md`
- `evidencias/historico/avaliacao_20261112_153315_qwen3_14b.md`
- `evidencias/comparacao_modelos_gemma_qwen.md`